


Logistic回归

韩雅妮

XiDian University

将线性回归应用到分类问题上存在的问题：



用直线对数据进行拟合，会出现 $h_{\theta}(x) > 1$ 或者 $h_{\theta}(x) < 0$ ，预测值超出范围。

Logistic回归

Logistic回归是一种分类算法，用于预测值为离散值0或1的情况。


Logistic回归模型：

希望 $0 \leq h_{\theta}(x) \leq 1$

定义： $h_{\theta}(x) = g(\theta^T x)$

$$g(z) = \frac{1}{1 + e^{-z}}$$

$$h_{\theta}(x) = \frac{1}{1 + e^{-\theta^T x}}$$



$g(z)$ 为sigmoid函数或者logistic函数，也就是logistic回归的名字来源。

输出值的预测


由sigmoid函数图像：

当 $z \geq 0$ 时， $g(z) \geq 0.5$ ，预测输出为1。

所以，预测



$$h_{\theta}(x) \geq 0.5, y=1;$$

$$h_{\theta}(x) < 0.5, y=0.$$



线性决策边界

例：



$$h_{\theta}(x) = g(\theta_0 + \theta_1 x_1 + \theta_2 x_2)$$



取 $\theta_0 = -3$, $\theta_1 = 1$, $\theta_2 = 1$

若 $-3 + x_1 + x_2 \geq 0$, 预测 $y=1$

$x_1 + x_2 = 3$ 时, $h_{\theta}(x) = 0.5$, 该函数作为决策边界。

非线性决策边界

例：



$$h_{\theta}(x) = g(\theta_0 + \theta_1 x_1 + \theta_2 x_2 + \theta_3 x_1^2 + \theta_4 x_2^2)$$

取 $\theta_0 = -1$, $\theta_1 = 0$, $\theta_2 = 0$, $\theta_3 = 1$, $\theta_4 = 1$

若 $-1 + x_1^2 + x_2^2 \geq 0$, 预测 $y = 1$

$x_1^2 + x_2^2 = 1$ 时, $h_{\theta}(x) = 0.5$, $y = 1$, 该函数作为决策边界。

Logistic回归中的代价函数


有m个样本: $(x^{(1)}, y^{(1)}), \dots, (x^{(m)}, y^{(m)})$

每个样本n+1个特征向量: $x^{(i)} = \begin{bmatrix} x_0^{(i)} \\ \dots \\ x_n^{(i)} \end{bmatrix}$


$$\begin{aligned} \text{线性回归的代价函数: } J(\theta) &= \frac{1}{m} \sum_{i=1}^m \frac{1}{2} (h_{\theta} x^{(i)} - y^{(i)})^2 \\ &= \frac{1}{m} \sum_{i=1}^m \text{cost}(h_{\theta} x^{(i)}, y^{(i)}) \end{aligned}$$

因为 $h_{\theta}(x)$ 是非线性函数, 代价函数非凸, 使用梯度下降算法并不能使 $J(\theta)$ 达到全局最优。因此, 需要修改代价函数。

$$\text{cost}(\mathbf{h}_{\theta}(\mathbf{x}), y) = \begin{cases} -\log(\mathbf{h}_{\theta}(\mathbf{x})) , y = 1 \\ -\log(1 - \mathbf{h}_{\theta}(\mathbf{x})) , y = 0 \end{cases}$$



若 $\mathbf{h}_{\theta}(\mathbf{x})=1$, $\text{cost}=0$, $y=1$;
当 $\mathbf{h}_{\theta}(\mathbf{x})$ 趋于0时, cost 趋于无穷, 而实际 $y=1$ 。



若 $h_{\theta}(x)=0$, $\text{cost}=0$, $y=0$;
当 $h_{\theta}(x)$ 趋于1时, cost 趋于无穷, 而实际 $y=0$ 。

$$\text{cost}(h_{\theta}(x), y) = -y \log(h_{\theta}(x)) - (1-y) \log(1-h_{\theta}(x))$$

代价函数:

$$J(\theta) = -\frac{1}{m} [\sum_{i=1}^m (y^{(i)} \log(h_{\theta}(x^{(i)})) + (1 - y^{(i)}) (\log(1 - h_{\theta}(x^{(i)})))]$$

Logistic回归中的参数

使用梯度下降算法:

repeat {


$$\begin{aligned}\theta_j &:= \theta_j - \alpha \frac{\partial}{\partial \theta_j} J(\theta) \\ &= \theta_j - \alpha \frac{1}{m} \sum_{i=1}^m (h_{\theta} x^{(i)} - y^{(i)}) x_j^{(i)}\end{aligned}$$

}

参数的更新与线性回归问题中的相同，但是线性回归中， $h_{\theta}(x) = \theta^T x$ ，而logistic回归中， $h_{\theta}(x) = \frac{1}{1 + e^{-\theta^T x}}$

正则化

将线性回归或者logistic回归应用到特定的机器学习中，可能会出现过度拟合的问题。



怎样避免过度拟合：

(1) 减少变量的数量

- a. 人工检查变量清单；
- b. 模型选择算法，自动选择特征变量。

(2) 正则化

思想：如果参数值较小，意味着假设的模型越简单，得到的函数越平滑，因此不容易出现过拟合问题。

线性回归的正则化

对线性回归的代价函数进行修改：

$$J(\theta) = \frac{1}{2m} [\sum_{i=1}^m (h_{\theta}x^{(i)} - y^{(i)})^2 + \lambda \sum_{j=1}^n \theta_j^2]$$

其中： $\lambda \sum_{j=1}^n \theta_j^2$ 为正则化项， λ 为正则化参数，控制两个不同目标之间的平衡。

两个目标：(1) 更好的拟合训练集；

(2) 保持参数尽可能的小。

如果 λ 的取值过大，对参数的惩罚会更大，这些参数可能会趋于0， $h_{\theta}(x) = \theta_0$ ，相当于用一条直线来拟合数据。

1. 梯度下降算法:

$$\theta_0 := \theta_0 - \alpha \frac{1}{m} \sum_{i=1}^m (h_{\theta} x^{(i)} - y^{(i)}) x_0^{(i)}$$

$$\begin{aligned} \theta_j &:= \theta_j - \alpha \left[\frac{1}{m} \sum_{i=1}^m (h_{\theta} x^{(i)} - y^{(i)}) x_j^{(i)} + \frac{\lambda}{m} \theta_j \right] \\ &= \theta_j \left(1 - \frac{\alpha \lambda}{m} \right) - \alpha \frac{1}{m} \sum_{i=1}^m (h_{\theta} x^{(i)} - y^{(i)}) x_j^{(i)} \end{aligned}$$

因为 α 很小，而样本数 m 很大，因此 $1 - \frac{\alpha \lambda}{m}$ 比1略小，接近于1。在每次迭代时，乘以比1略小的数，每次把参数缩一点点，然后进行和之前一样的更新操作。

2. 正规方程

m个样本: $(x^{(1)}, y^{(1)}), \dots, (x^{(m)}, y^{(m)})$

n个特征向量: $x^{(i)} = \begin{bmatrix} x_1^{(i)} \\ \vdots \\ x_n^{(i)} \end{bmatrix}$

构建 $X = \begin{bmatrix} (x^{(1)})^T \\ \vdots \\ (x^{(m)})^T \end{bmatrix}$, $y = \begin{bmatrix} y^{(1)} \\ \vdots \\ y^{(m)} \end{bmatrix}$

$$\theta = (X^T X + \lambda \begin{bmatrix} 0 & \dots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \dots & 1 \end{bmatrix})^{-1} X^T y$$

逻辑回归的正则化

代价函数:

$$J(\theta) = -\frac{1}{m} [\sum_{i=1}^m (y^{(i)} \log(h_{\theta}(x^{(i)})) + (1 - y^{(i)}) (\log(1 - h_{\theta}(x^{(i)})))] + \frac{\lambda}{2m} \sum_{j=1}^n \theta_j^2$$

梯度下降算法:

$$\theta_0 := \theta_0 - \alpha \frac{1}{m} \sum_{i=1}^m (h_{\theta} x^{(i)} - y^{(i)}) x_0^{(i)}$$

$$\theta_j := \theta_j - \alpha \left[\frac{1}{m} \sum_{i=1}^m (h_{\theta} x^{(i)} - y^{(i)}) x_j^{(i)} + \frac{\lambda}{m} \theta_j \right]$$



Thanks

